

Apprentissage continu hybride pour la classification des consommables de santé.

Etudiants: Taher LMOUDEN - Mohamed DEMES

Encadrant: Massinissa HAMIDI

Problématique

L'augmentation des déchets médicaux, coûtant environ 36 milliards de dollars globalement en 2020^[1], souligne l'importance de leur recyclage. Cependant, la dépendance au travail humain dans ce processus présente des risques d'erreur et de blessures. Utiliser l'intelligence artificielle pour automatiser le recyclage pourrait réduire ces risques tout en améliorant l'efficacité.

Scénario

Nous envisageons d'adopter une approche innovante pour le recyclage des déchets médicaux en déployant un modèle d'IA qui s'appuie sur les modèles de fondation. Ce système intelligent, une fois intégré dans des environnements réels, sera capable de s'ajuster et d'apprendre de manière autonome face à de nouveaux types de déchets, grâce à l'apprentissage en few-shot. Cette solution permet d'augmenter à la fois l'efficacité et la sécurité du processus de recyclage.

Paramètres expérimentaux:

Dataset utilisé:^[2]

- Taille: 4245 images.
- nombre de classes: 13 classes.

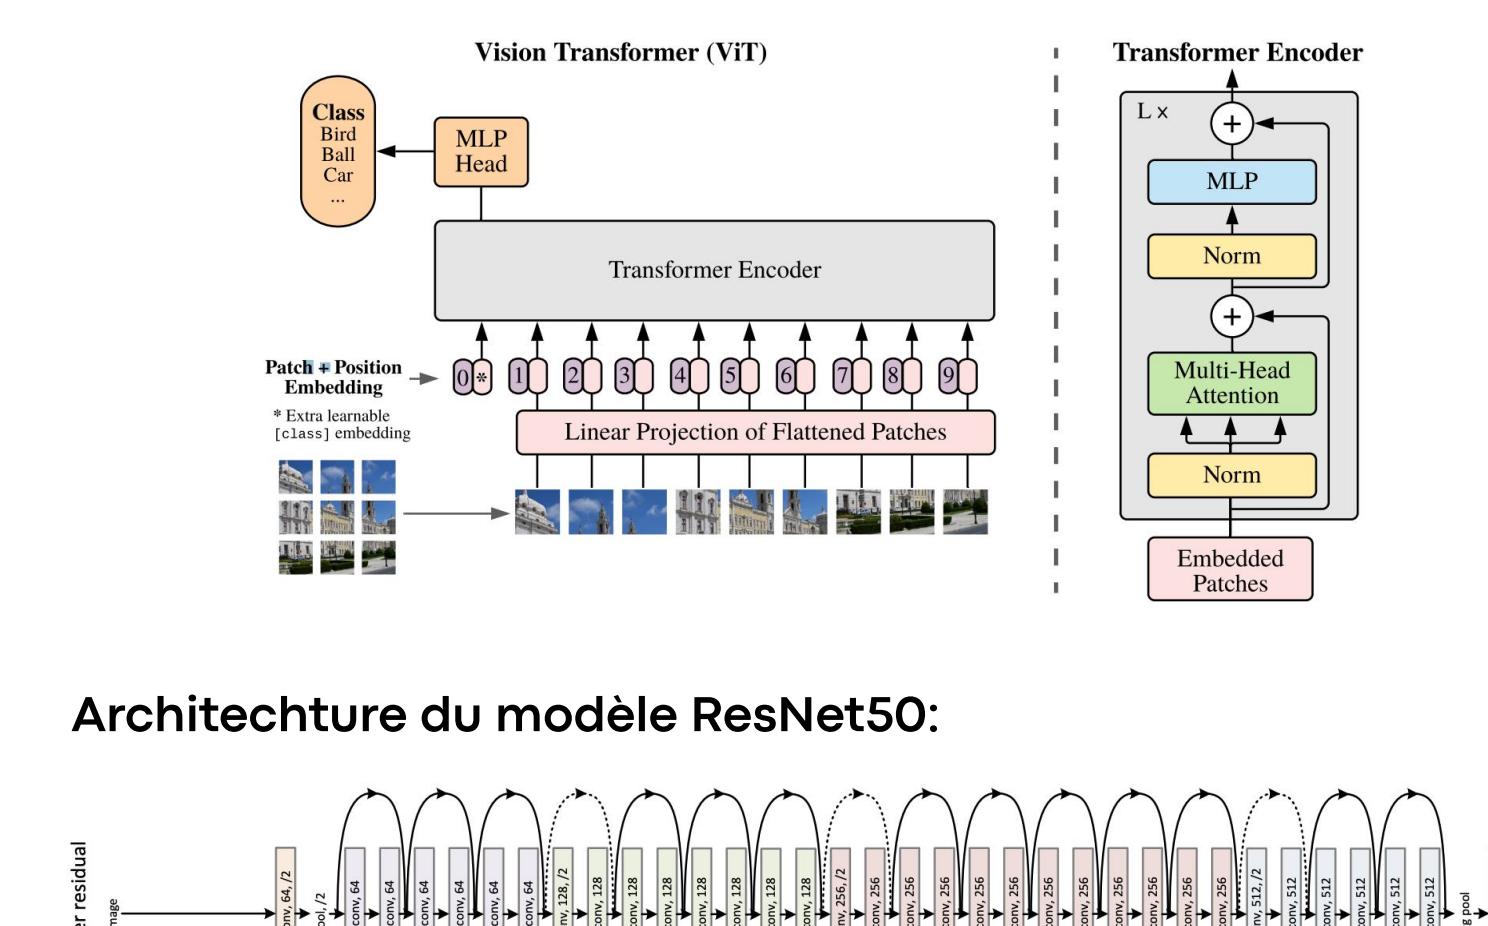
Distribution du dataset:

- Training: 70% (2967 images)
- Validation: 15% (629 images)
- Testing: 15% (649 images)

Modèles fondamentaux utilisé: 😊

Nom du modèle	Nombre des paramètres	Dataset d'entraînement	Nombre d'images	Nombre des classes du dataset
ViT <small>google/vit-base-patch16-224</small>	86.6 Millions	ImageNet-21K, finetuned sur ImageNet 2012	14 Millions, finetuned sur 1 Million	1000 classes
ResNet50 <small>microsoft/resnet-50</small>	25.6 Millions	ImageNet-1K	1 Million	1000 classes

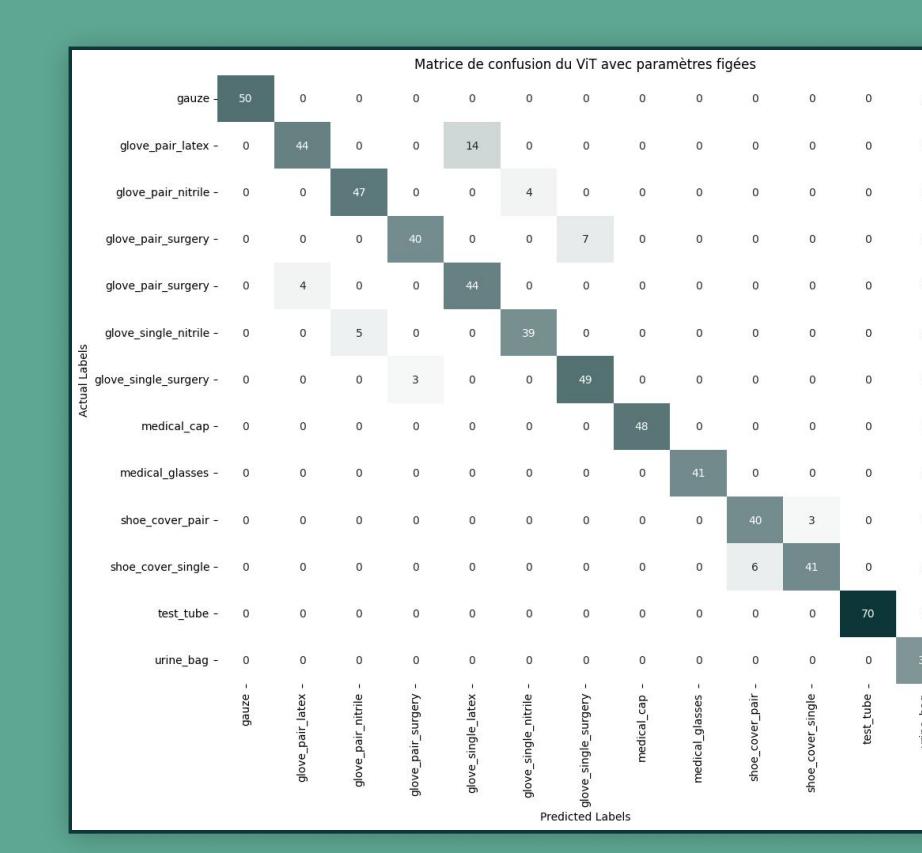
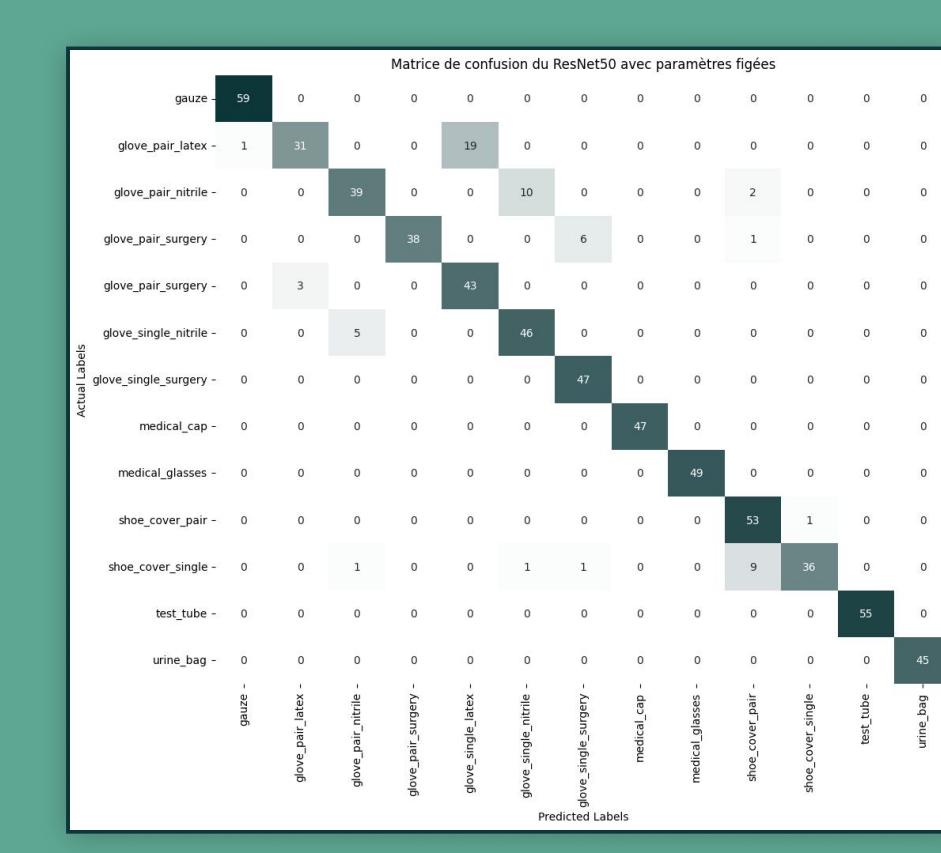
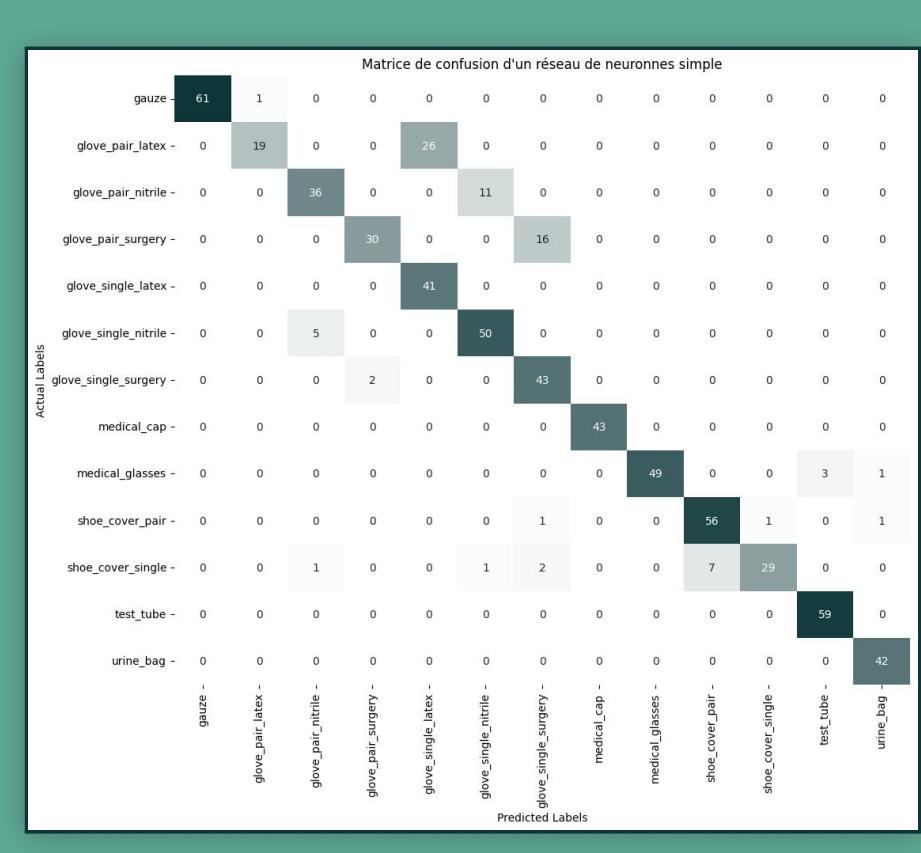
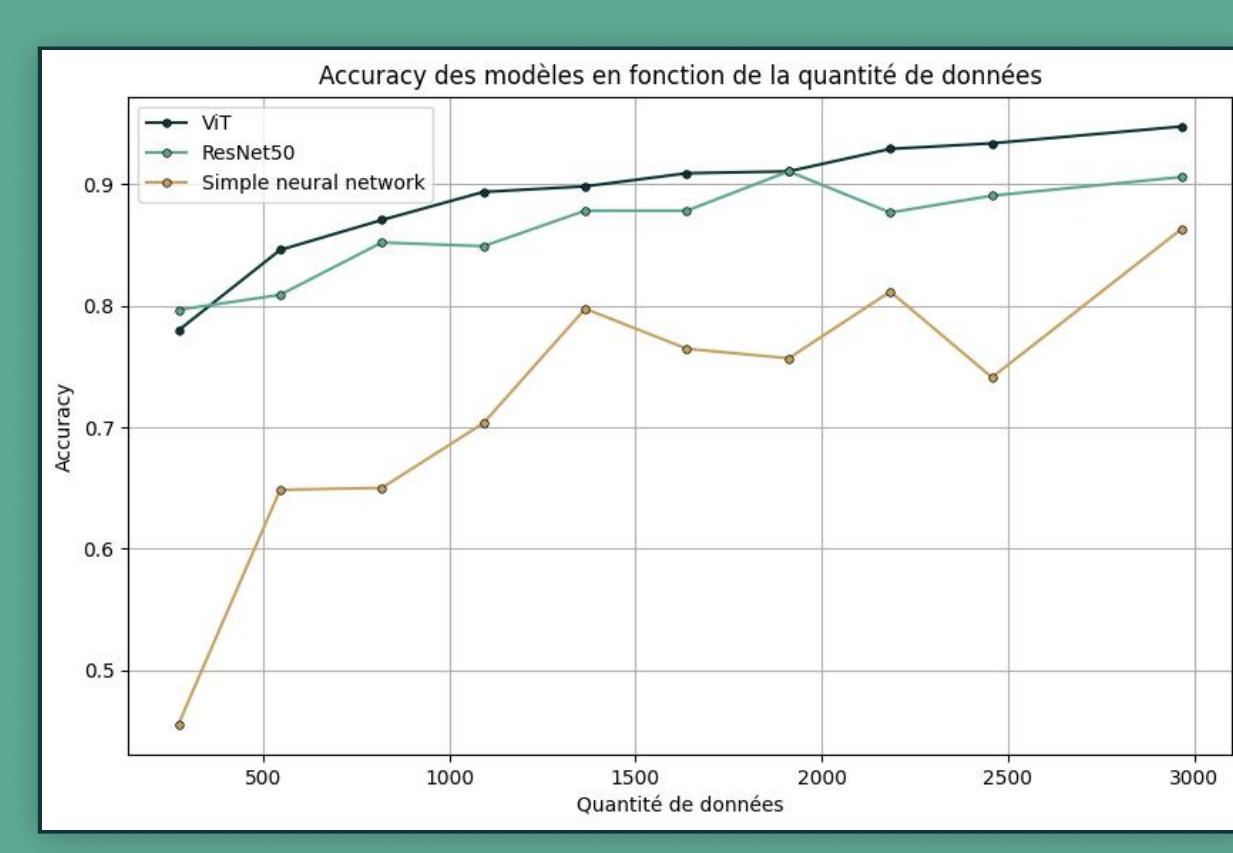
Architectures des modèles:



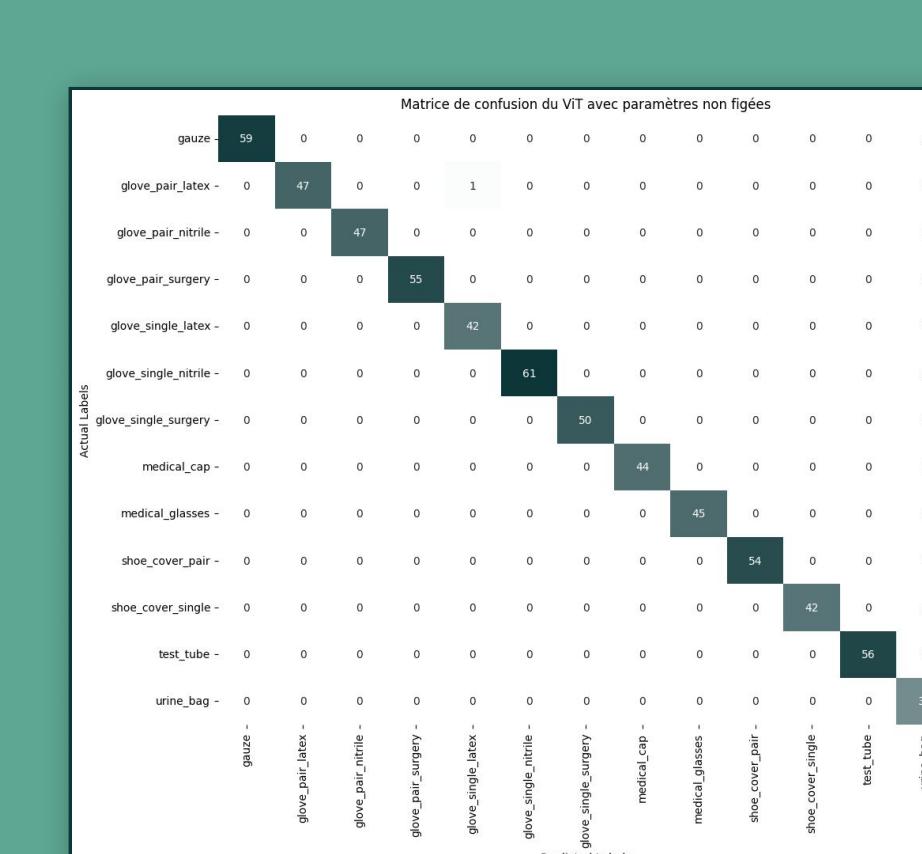
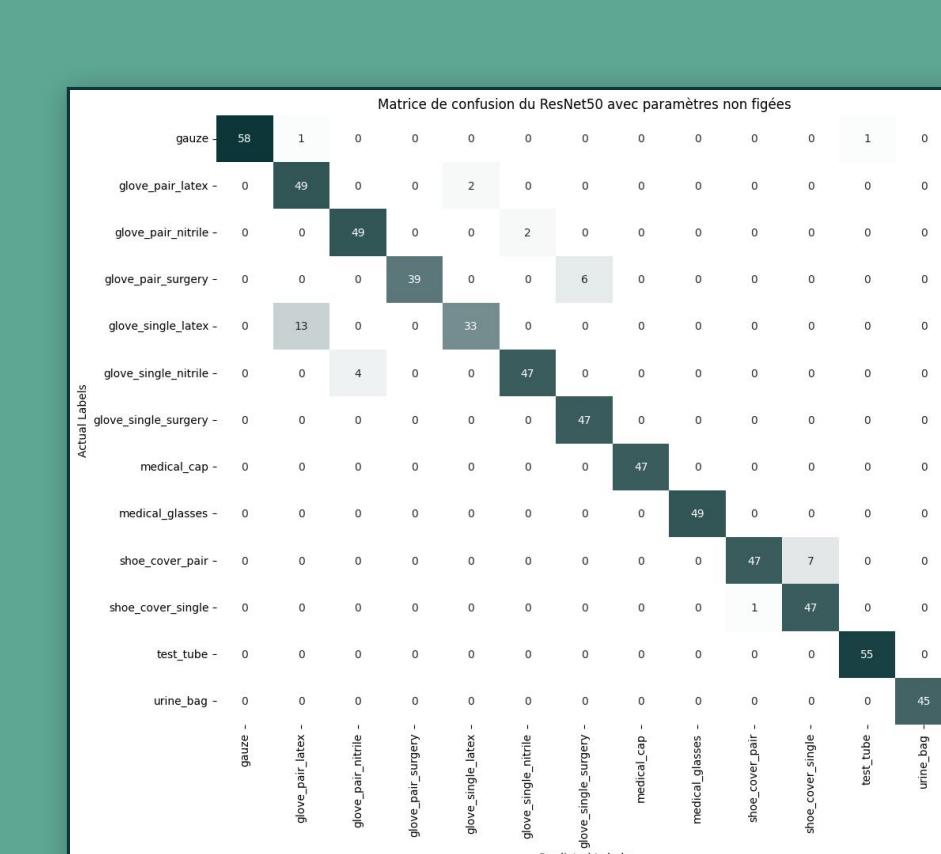
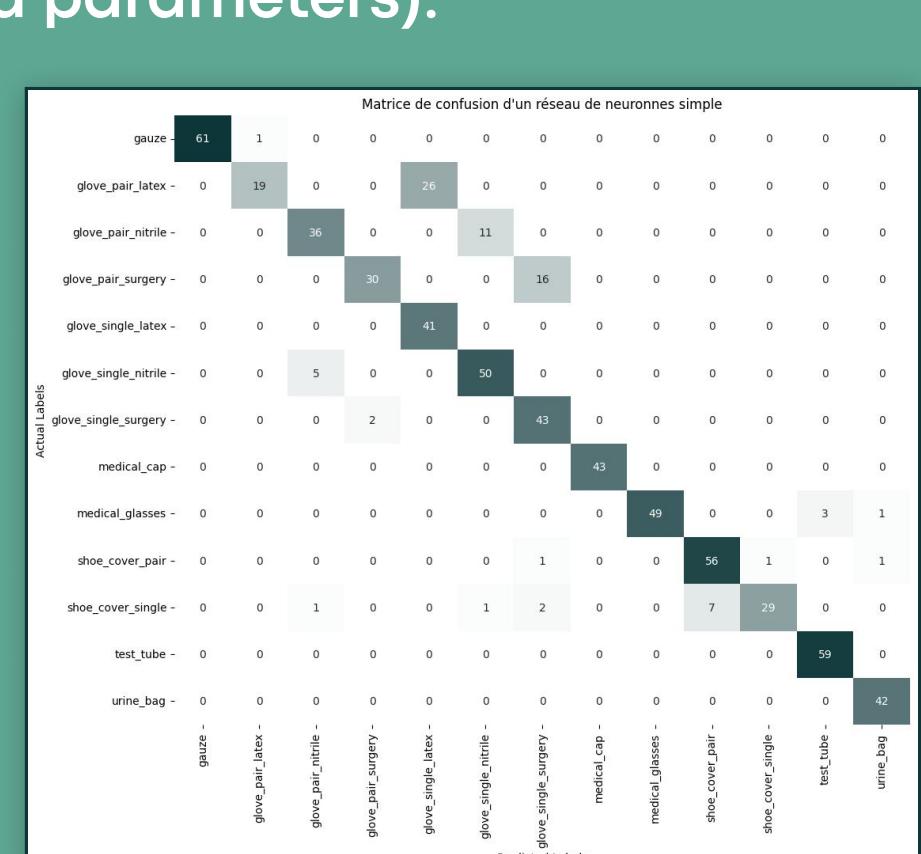
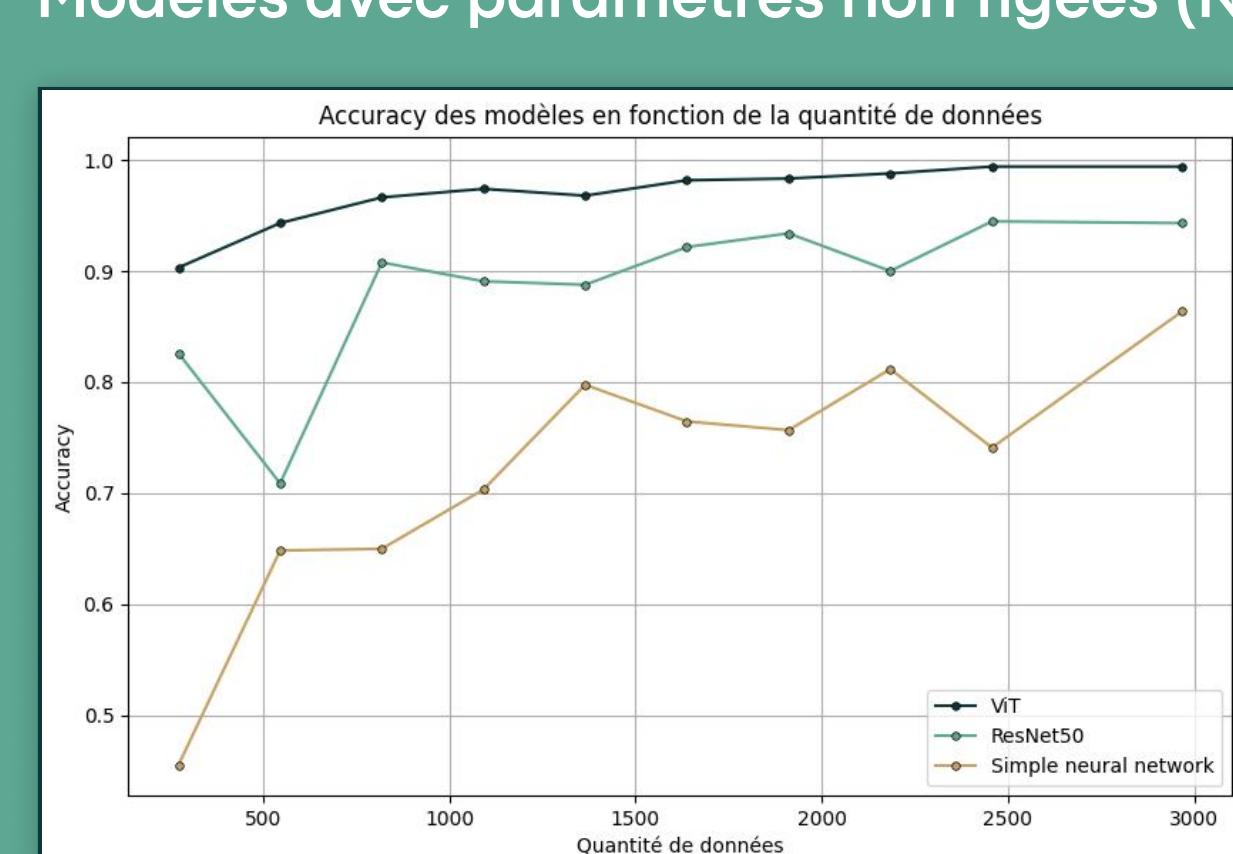
En outre, nous avons employé un modèle simple de réseau de neurones afin de comparer les résultats.

Expériences

Modèles avec paramètres figés (Freezed parameters):



Modèles avec paramètres non figés (Non freezed parameters):



Conclusion

Selon les expériences que nous avons menées, il apparaît clairement que les modèles de fondation que nous avons utilisés apprennent nos données beaucoup plus rapidement. Ils sont capables d'atteindre de bonnes précisions même avec un minimum de données, comparativement aux modèles plus simples. De plus, ces modèles fournissent des précisions très élevées avec tous les échantillons testés, démontrant ainsi leur efficacité supérieure pour l'apprentissage.

Perspectives

Dans les prochaines étapes de notre projet, nous envisageons d'explorer la capacité d'adaptation des modèles de fondation à l'apprentissage continu. Pour cela, nous proposons d'initier l'entraînement de nos modèles sur un nombre limité de classes, puis d'ajouter progressivement des classes supplémentaires. Cette méthode nous permettra d'observer comment les modèles réagissent à l'introduction successive de nouvelles classes et de vérifier leur aptitude à maintenir la performance de prédiction sur toutes les classes déjà apprises.

